BAB IV
HASIL ANALISIS DAN PEMBAHASAN

4.1 Hasil Identifikasi Faktor yang Signifikan Pada Kredit Bermasalah

Kredit bermasalah (Non-Performing Loan/NPL) umumnya tidak disebabkan oleh satu faktor saja, melainkan merupakan hasil dari kombinasi berbagai aspek, baik dari sisi debitur, kreditur (bank), maupun kondisi eksternal. Pada analisis kali ini, digunakan 8 variabel independent yang diduga mempengaruhi proforma kredit nasabah. Oleh karena itu perlu dilihat terlebih dahulu karakteristik dari faktor-faktor yang diduga mempengaruhi kelancaran nasabah dalam persoalan kredit di Bank XYZ. Berikut merupakan deksriptif data yang menggambarkan secara umum kondisi kreditur di Bank XYZ.

Tabel 4.1 Karakteristik Data Transaksi Kredit Bank XYZ

Ukuran	Plafon		Bunga
Minimum	Rp	1,700,671.00	0.40%
Maximum	Rp	25,000,000,000.00	42.00%
Mean	Rp	395,695,307.55	9.93%
Median	Rp	200,000,000	7.00%

Tabel 4.1 merupakan gambaran umum pembiayaan kredit oleh Bank XYZ kepada kreditur. Dapat dilihat bahwa rentang plafon kredit yang sangat lebar menunjukkan adanya heterogenitas dalam skala pembiayaan, yang mencerminkan keberagaman jenis dan ukuran usaha nasabah. Nilai rata-rata plafon yang lebih tinggi dibandingkan median menunjukkan bahwa distribusi plafon kredit cenderung *right-skewed*, dimana terdapat sejumlah kecil pinjaman bernilai sangat besar yang mempengaruhi rata-rata. Bunga pinjaman yang diberikan oleh Bank XYZ terdapat nilai maksimum bunga yang cukup tinggi, namun rata-rata dan median bunga menunjukkan bahwa sebagian besar kredit berada pada tingkat suku bunga yang relatif moderat. Rentang suku bunga yang sangat luas mengindikasikan adanya variasi risiko kredit atau perbedaan jenis produk pembiayaan yang diberikan kepada nasabah.

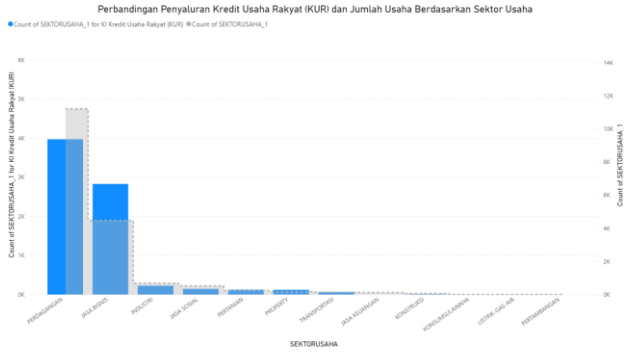

Gambar 4.1 *Chart* perbandingan antara jumlah KUR dan total usaha berdasarkan sektor

Bagan pada Gambar 4.1 menunjukkan bahwa penyaluran Kredit Usaha Rakyat (KUR) didominasi oleh sektor perdagangan dan jasa bisnis. Sementara itu, sektor-sektor produktif seperti industri dan pertanian masih memiliki proporsi yang relatif kecil. Hal ini menunjukkan adanya ketimpangan distribusi pembiayaan, di mana KUR lebih banyak mengalir ke sektor dengan perputaran cepat dan risiko rendah. Temuan ini mengindikasikan perlunya strategi untuk mendorong akses pembiayaan pada sektor produktif guna meningkatkan dampak ekonomi jangka Panjang.

Untuk melihat hubungan antara faktor-faktor yang diduga mempengaruhi performa kreditur gagal bayar atau sukses dapat dilihat dengan menggunakan metode korelasi Pearson. Berikut ini merupakan gambar dari sebuah tabel matriks korelasi antara 9 variabel menggunakan metode korelasi Pearson.

Attributes	Plafon	Bunga	JW	Sektor	Lokasi	Jenis	Agunan	Usaha	NPL
Plafon	1	-0.085	-0.048	0.032	-0.017	0.032	0.123	-0.038	-0.103
Bunga	-0.085	1	-0.142	-0.015	-0.033	0.214	-0.015	0.077	0.343
JW	-0.048	-0.142	1	0.026	-0.017	0.138	-0.004	-0.103	0.003
Sektor	0.032	-0.015	0.026	1	-0.026	-0.031	-0.010	-0.195	-0.049
Lokasi	-0.017	-0.033	-0.017	-0.026	1	-0.061	-0.004	0.030	-0.081
Jenis	0.032	0.214	0.138	-0.031	-0.061	1	-0.004	0.090	0.405
Agunan	0.123	-0.015	-0.004	-0.010	-0.004	-0.004	1	-0.001	-0.025
Usaha	-0.038	0.077	-0.103	-0.195	0.030	0.090	-0.001	1	0.149
NPL	-0.103	0.343	0.003	-0.049	-0.081	0.405	-0.025	0.149	1

Gambar 4.2 Output Matriks Korelasi 9 Variabel

Berdasarkan hasil matriks korelasi terhadap sembilan variabel yang ditampilkan pada Gambar 4.1, diperoleh beberapa temuan sebagai berikut. Pertama, ditinjau dari hubungan antara variabel independen dengan variabel dependen (NPL), terdapat dua variabel yang menunjukkan korelasi relatif lebih tinggi dibandingkan variabel lainnya, yaitu **jenis kredit** dan **tingkat bunga**. Variabel jenis kredit memiliki koefisien korelasi sebesar 0,405 yang mengindikasikan adanya hubungan positif dengan kekuatan sedang terhadap NPL. Hal ini menunjukkan bahwa variasi jenis kredit memiliki keterkaitan yang cukup berarti terhadap peningkatan risiko kredit bermasalah. Sementara itu, variabel tingkat bunga memiliki koefisien korelasi sebesar 0,343 yang juga menunjukkan hubungan positif, hal ini mengindikasikan bahwa semakin tinggi tingkat bunga, maka kecenderungan terjadinya kredit bermasalah juga meningkat.

Di sisi lain, variabel lain seperti plafon kredit (-0,103), lokasi (-0,081), sektor usaha (-0,049), dan agunan (-0,025) menunjukkan hubungan negatif dengan NPL, namun dengan kekuatan yang sangat lemah sehingga secara praktis pengaruhnya terhadap kredit bermasalah relatif kecil. Variabel jangka waktu kredit (0,003) bahkan menunjukkan hampir tidak adanya hubungan dengan NPL. Variabel usaha (0,149) memiliki hubungan positif namun dalam kategori lemah.

Kedua, hasil analisis terhadap hubungan antar variabel independen menunjukkan bahwa tidak terdapat korelasi yang tinggi di antara variabel-variabel tersebut. Seluruh nilai koefisien korelasi berada jauh di bawah ambang batas umum multikolinearitas (≥ 0,70). Dengan demikian, dapat disimpulkan bahwa tidak terdapat indikasi multikolinearitas yang kuat dalam data, sehingga seluruh variabel independen masih layak untuk digunakan secara simultan dalam pengembangan model prediksi.

Berdasarkan keseluruhan hasil identifikasi, dapat disimpulkan bahwa faktor yang paling berdampak dalam memicu terjadinya kredit bermasalah (NPL) adalah jenis kredit dan tingkat bunga. Kedua variabel ini memiliki hubungan yang paling kuat dibandingkan variabel lainnya, sehingga dapat dianggap sebagai faktor utama yang perlu menjadi perhatian dalam pengelolaan risiko kredit. Sementara itu, variabel lainnya berperan sebagai faktor pendukung dengan tingkat pengaruh yang relatif kecil.

Dengan demikian, dalam tahap pemodelan selanjutnya, variabel jenis kredit dan tingkat bunga dapat diprioritaskan sebagai prediktor utama, sementara variabel lainnya tetap dipertimbangkan untuk menangkap kemungkinan interaksi atau pola hubungan yang lebih kompleks.

4.2 Hasil Performa Model Prediksi Kredit Bermasalah

Perbedaan kreditur bermasalah atau NPL (Non-performing Loan) pada bank XYZ dapat dilihat karakteristiknya pada Gambar 4.2 sebagai berikut.

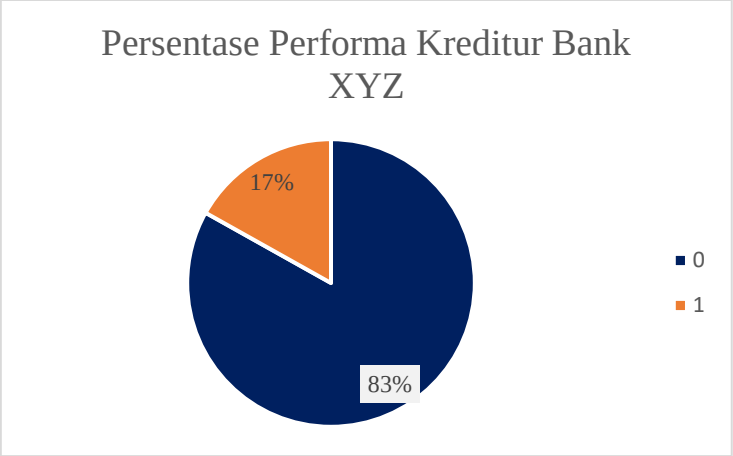

Gambar 4.3 Persentase kreditur bermasalah dengan kreditur lancar

Berdasarkan Gambar 4.3 terlihat adanya perbedaan persentase yang cukup signifikan antara kreditur lancar dan kreditur bermasalah (Non-Performing Loan/NPL), yaitu masing-masing sebesar 83% dan 17%. Meskipun proporsi kreditur bermasalah relatif lebih kecil dibandingkan kreditur lancar, angka 17% tetap merupakan tingkat yang cukup tinggi dan berpotensi memberikan dampak negatif terhadap kinerja serta kesehatan keuangan suatu institusi perbankan.

Oleh karena itu, kondisi ini perlu mendapatkan perhatian serius dan penanganan yang tepat. Dalam penelitian ini, dilakukan analisis prediksi terhadap performa kreditur menggunakan pendekatan statistika dan *machine learning*. Hasil prediksi ini diharapkan dapat menjadi dasar pertimbangan bagi Bank XYZ dalam mengidentifikasi potensi risiko kredit sejak dini, serta sebagai bahan evaluasi dalam merumuskan strategi pengelolaan risiko kredit yang lebih efektif.

Pada penelitian ini dilakukan pemodelan untuk memprediksi kemungkinan terjadinya kredit bermasalah (*Non-Performing Loan/NPL*) menggunakan beberapa metode *machine learning*, yaitu *Logistic Regression* (LR), *Random Forest* (RF), dan *Extreme Gradient Boosting* (XGBoost). Pemilihan metode ini didasarkan pada kemampuannya dalam menangani permasalahan klasifikasi serta dalam menangkap pola hubungan antar variabel, baik yang bersifat linear maupun non-linear.

Untuk menguji kestabilan model, dilakukan beberapa skenario pembagian data (*data splitting*), yaitu 90:10, 80:20, dan 70:30 antara data pelatihan (*training*) dan data pengujian (*testing*).

Proses pemodelan dilakukan melalui beberapa tahapan utama, yaitu:

1. Pembagian data menjadi data latih dan data uji dengan tiga skenario rasio.
2. Pelatihan model menggunakan masing-masing algoritma (*Logistic Regression*, *Random Forest*, dan XGBoost).
3. Evaluasi model menggunakan metrik performa *accuracy*, *precision*, *recall* dan *F1-score*.

Pendekatan ini bertujuan untuk memperoleh model dengan performa terbaik serta memastikan bahwa hasil yang diperoleh konsisten pada berbagai skenario pembagian data.

Secara umum, algoritma klasifikasi data dapat dilihat pada gambar berikut ini

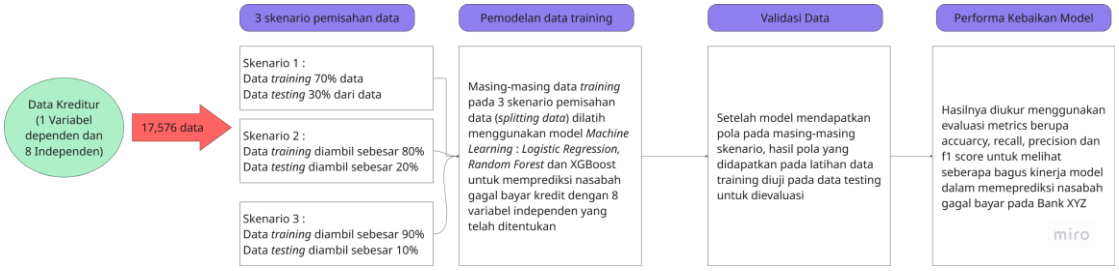

Gambar 4.4 Proses Klasifikasi Prediksi Model

Penelitian ini menggunakan pendekatan komparatif dengan tiga skenario pembagian data dan tiga algoritma machine learning untuk memprediksi gagal bayar kredit. Proses ini dirancang untuk memastikan model yang dihasilkan tidak hanya memiliki performa tinggi, tetapi juga stabil dan mampu melakukan generalisasi dengan baik terhadap data baru

Berikut ini merupakan hasil evaluasi *metrics* dari performa ketiga *machine learning*.

Tabel 4.2 Tabel Skenario *Split* Data 70:30 Evaluasi Performa Model

Model	Evaluasi *Performance* ML			
	Accuracy	*Precision*	*Recall*	*F1-score*
Logistic Regression	77,62%	75,63%	81,50%	78,45%
Random Forest	81,54%	79,72%	84,60%	82,08%
XGBoost	**91,27%**	**92,23%**	**90,14%**	**91,17%**

Tabel 4.2 menggambarkan seberapa baik kinerja performa machine learning pada scenario pembagian data menjadi 70% untuk data *training* dan 30% untuk data *testing*. Hal ini dilakukan agar dapat melihat kinerja model dengan baik. Dapat dilihat bahwa XGboost adalah model terbaik pada kasus ini jika dibandingkan dengan *Logistic Regression* dan *Random Forest*.

Tabel 4.2.1 Tabel Skenario *Split* Data 80:20 Evaluasi Performa Model

Model	Evaluasi *Performance* ML			
	Accuracy	*Precision*	*Recall*	*F1-score*
Logistic Regression	78,03%	75,84%	82,27%	78,92%
Random Forest	81,84%	79,91%	85,08%	82,41%
XGBoost	**91,43%**	**92,25%**	**90,45%**	**91,34%**

Tabel 4.2.1 merupakan hasil performa model dengan scenario 80% data dilatih sebagai data training dan sisanya untuk data *testing*. Dapat dilihat bahwa XGboost adalah model terbaik pada kasus ini jika dibandingkan dengan *Logistic Regression* dan *Random Forest*.

Tabel 4.2.2 Tabel Skenario *Split* Data 90:10 Evaluasi Performa Model

Model	Evaluasi *Performance* ML			
	Accuracy	Precision	Recall	F1-score
Logistic Regression	78,06%	75,34%	83,44%	79,18%
Random Forest	82,27%	79,52%	86,93%	83,06%
XGBoost	**90,93%**	**91,70%**	**90,01%**	**90,84%**

Tabel 4.2.1 merupakan hasil performa model dengan scenario 80% data dilatih sebagai data training dan sisanya untuk data *testing*. Dapat dilihat bahwa XGboost adalah model terbaik pada kasus ini jika dibandingkan dengan *Logistic Regression* dan *Random Forest*.

Tabel 4.2.3 Rata-rata Kinerja Performa Model ML dari Tiga Skenario

Model	**Akurasi (Avg)**	**Precision (Avg)**	**Recall (Avg)**	**F1-Score (Avg)**
Logistic Regression	77,90%	75,60%	82,40%	78,85%
Random Forest	81,88%	79,72%	85,54%	82,52%
XGBoost	**91,21%**	**92,06%**	**90,20%**	**91,12%**

Berdasarkan hasil pengujian terhadap tiga algoritma machine learning, yaitu *Logistic Regression, Random Forest*, dan XGBoost, dilakukan evaluasi kinerja model menggunakan beberapa metrik utama, yaitu akurasi, precision, recall, dan *F1-score*. Pengujian dilakukan pada tiga skenario pembagian data, yaitu 70:30, 80:20, dan 90:10 untuk memastikan konsistensi dan stabilitas model.

Secara umum, hasil pengujian menunjukkan bahwa model XGBoost memiliki performa terbaik dibandingkan dengan model lainnya pada seluruh skenario pembagian data. Hal ini terlihat dari nilai akurasi yang konsisten tinggi, yaitu berkisar antara 90,93% hingga 91,43%. Selain itu, nilai *precision* pada kelas kredit bermasalah (NPL) juga berada di atas 91%, yang menunjukkan bahwa model memiliki tingkat ketepatan yang tinggi dalam mengklasifikasikan kredit bermasalah. Nilai *recall* yang mencapai sekitar 90% mengindikasikan bahwa sebagian besar kasus NPL berhasil terdeteksi oleh model. Kombinasi *precision* dan *recall* yang tinggi tersebut menghasilkan nilai *F1-score* rata-rata sebesar 91,12%, yang mencerminkan keseimbangan yang sangat baik antara kemampuan deteksi risiko dan akurasi klasifikasi.

Sementara itu, model *Random Forest* menunjukkan performa yang cukup baik dengan nilai akurasi rata-rata sebesar 81,88%. Model ini memiliki keunggulan pada nilai recall kelas NPL yang relatif tinggi, yaitu sekitar 85,54%, yang menunjukkan kemampuan yang baik dalam mengidentifikasi kredit bermasalah. Namun demikian, nilai precision yang berada di kisaran 79,72% mengindikasikan bahwa masih terdapat cukup banyak kesalahan dalam mengklasifikasikan kredit lancar sebagai kredit bermasalah (*false positive*). Nilai *F1-score* rata-rata sebesar 82,52% menunjukkan bahwa model ini cukup seimbang, meskipun masih berada di bawah XGBoost.

Di sisi lain, model Logistic Regression memiliki performa paling rendah di antara ketiga model yang diuji, dengan nilai akurasi rata-rata sebesar 77,90%. Meskipun demikian, model ini tetap menunjukkan nilai *recall* yang cukup baik, yaitu sekitar 82,40%, yang berarti model masih mampu mendeteksi sebagian besar kredit bermasalah. Akan tetapi, nilai *precision* yang lebih rendah, yaitu sekitar 75,60%, menunjukkan adanya kecenderungan model dalam menghasilkan false positive yang lebih tinggi. Hal ini berdampak pada nilai *F1-score* yang hanya mencapai rata-rata 78,85%.

Dalam konteks manajemen risiko perbankan, hasil ini memiliki implikasi yang penting. Kesalahan klasifikasi dalam bentuk false negative, yaitu ketika kredit bermasalah diprediksi sebagai kredit lancar, merupakan risiko yang paling krusial karena dapat menyebabkan kerugian finansial langsung bagi bank. Oleh karena itu, model dengan nilai *recall* yang tinggi pada kelas NPL menjadi lebih diutamakan. Dalam hal ini, XGBoost dan Random Forest menunjukkan keunggulan dibandingkan *Logistic Regression*.

Namun demikian, *precision* juga tetap perlu diperhatikan karena berkaitan dengan efisiensi bisnis. Nilai *precision* yang rendah dapat menyebabkan banyaknya kredit yang sebenarnya layak namun ditolak (*false positive*), sehingga berpotensi menurunkan pendapatan bank. Oleh karena itu, model yang ideal adalah model yang mampu menyeimbangkan *recall* dan *precision*, sebagaimana tercermin dalam nilai *F1-score*.

Berdasarkan keseluruhan hasil evaluasi, dapat disimpulkan bahwa model XGBoost merupakan model yang paling optimal untuk digunakan dalam prediksi *Non-Performing Loan* (NPL) pada Bank XYZ. Model ini tidak hanya memiliki tingkat akurasi tertinggi, tetapi juga mampu memberikan keseimbangan terbaik antara kemampuan deteksi risiko dan efisiensi keputusan kredit. Dengan demikian, penerapan model XGBoost diharapkan dapat membantu bank dalam meningkatkan kualitas pengambilan keputusan kredit serta meminimalkan potensi kerugian akibat kredit bermasalah.

4.3 *Dashboard profile* Performa Kreditur di Bank XYZ

Untuk membantu memudahkan dalam profiling setiap kreditur pada Bank XYZ, pada analisis kali ini akan ditampilkan Dashboard Profile Customer untuk mendapatkan insight tambahan yang dapat dipertimbangkan oleh Bank XYZ dalam mengambil keputusan.

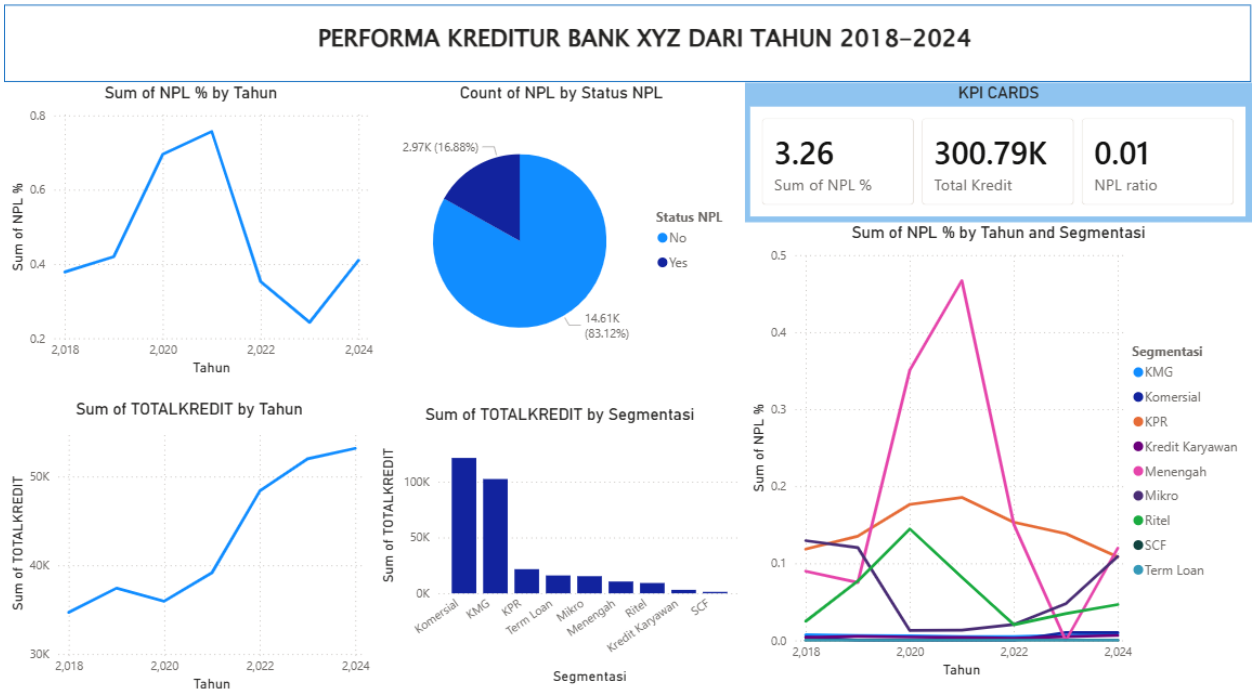

Gambar 4.5 Dashboard Profile Performansi Kreditur Bank XYZ

Dashboard pada Gambar 4.5 menunjukkan bahwa total kredit Bank XYZ mengalami peningkatan dari tahun ke tahun, yang mencerminkan ekspansi bisnis yang cukup agresif. Namun demikian, rasio *Non-Performing Loan* (NPL) menunjukkan fluktuasi, dengan penurunan signifikan pada tahun 2022 hingga 2023, sebelum kembali meningkat pada tahun 2024. Hal ini mengindikasikan bahwa meskipun pertumbuhan kredit meningkat, kualitas kredit masih menghadapi tekanan, khususnya pada periode terakhir.

Berdasarkan segmentasinya, risiko kredit yang cukup tinggi segment kredit menengah karena memiliki pola yang sangat fluktuatif (35% → 46% → 15% → 0% → 11.97%) yang artinya segmen ini paling tidak stabil pergerakannya disusul oleh segmen KPR, Mikro dan Ritel. Sedangkan sisanya termasuk kedalam kategori segmentasi rendah.

SEGMENTASI	2018			2019			2020			2021			2022			2023			2024		
	TOTAL KREDIT	BAKI DEBET NPL	NPL %	TOTAL KREDIT	BAKI DEBET NPL	NPL %	TOTAL KREDIT	BAKI DEBET NPL	NPL %	TOTAL KREDIT	BAKI DEBET NPL	NPL %	TOTAL KREDIT	BAKI DEBET NPL	NPL %	TOTAL KREDIT	BAKI DEBET NPL	NPL %	TOTAL KREDIT	BAKI DEBET NPL	NPL %
Komersial	13,939	63	0.45%	15,313	-	0.00%	16,635	-	0.00%	17,172	-	0.00%	20,065	-	0.00%	18,996	196	1.03%	19,154	196	1.02%
Menengah	1,099	99	8.98%	2,231	168	7.52%	865	303	35.07%	1,012	473	46.69%	1,964	296	15.08%	1,920	-	0.00%	1,471	176	11.97%
Ritel	1,514	38	2.49%	645	50	7.70%	713	103	14.47%	922	76	8.20%	1,294	26	2.04%	1,926	67	3.48%	2,224	104	4.66%
KPR	4,311	511	11.86%	3,603	487	13.52%	3,209	566	17.65%	2,822	524	18.56%	2,528	388	15.34%	2,493	345	13.85%	2,660	288	10.84%
KMG	9,072	66	0.73%	10,854	67	0.62%	12,012	70	0.59%	14,176	72	0.51%	16,834	82	0.49%	19,146	128	0.67%	20,271	187	0.92%
Mikro	1,129	146	12.94%	1,404	169	12.06%	1,298	17	1.29%	1,665	22	1.33%	2,564	53	2.06%	3,659	175	4.77%	3,623	395	10.90%
Kredit Karyawan	442	2	0.39%	429	2	0.53%	432	2	0.44%	433	2	0.39%	443	1	0.28%	459	2	0.48%	461	3	0.65%
Term Loan	3,193	-	0.00%	2,946	-	0.00%	499	-	0.00%	500	-	0.00%	2,300	-	0.00%	3,300	-	0.00%	3,250	-	0.00%
SCF	-	-	-	-	-	-!	282	-	0.00%	456	-	0.00%	381	-	0.00%	105	-	0.00%	66	-	0.00%
GRAND TOTAL	34,700	925	2.67%	37,426	944	2.52%	35,946	1,062	2.95%	39,159	1,168	2.98%	48,375	846	1.75%	52,004	914	1.76%	53,180	1,349	2.54%

Tren rasio NPL menunjukkan pola yang dinamis. Pada periode 2020 hingga 2021, rasio NPL relatif stabil di kisaran 3%. Selanjutnya terjadi penurunan signifikan pada tahun 2022 hingga mencapai 1,75% dan cenderung stabil pada tahun 2023. Namun, pada tahun 2024 terjadi peningkatan kembali menjadi 2,54%. Fenomena ini mengindikasikan adanya potensi peningkatan risiko kredit yang perlu diantisipasi oleh manajemen.